

Instituto Tecnológico y de Estudios Superiores de Monterrey



Análisis de Grandes Volúmenes de Datos (Grupo 10)

Proyecto: Base de datos de Big Data

José Alberto Rodríguez Sotomayor - A01796604

Héctor Magaña - A00823440

Emanuel Flores Martínez - A01796497

Ángel García Ortega - A01796653

12 de mayo del 2026

Introducción

El presente documento presenta la construcción de una muestra representativa (M) a partir de una base de datos histórica de criptomonedas obtenida de Binance. La finalidad es analizar el comportamiento del mercado mediante técnicas de particionamiento y muestreo estratificado, asegurando que la muestra preserve las características estructurales de la población objetivo (P).

La base de datos utilizada (D) contiene información histórica de trading para los pares BTCUSDT, ETHUSDT y XRPUSDT, con resolución de 1 minuto cubriendo el periodo enero 2023 - diciembre 2024. Incluye variables OHLC (open, high, low, close), volumen, número de transacciones y variables derivadas de comportamiento de mercado calculadas con Pyspark.

Caracterización de la población

Para caracterizar la población objetivo se utilizó el dataset "Binance Full History", recuperado de <https://www.kaggle.com/datasets/jorijnsmit/binance-full-history/data>, primero, se extrae la siguiente información:

La base de datos está compuesta por archivos CSV provenientes de datos históricos de Binance. Cada registro representa un intervalo de 1 minuto de actividad de mercado.

Variables originales del dataset:

- open_time: tiempo de apertura del intervalo
- open: precio de apertura
- high: precio máximo
- low: precio mínimo
- close: precio de cierre
- volume: volumen transado
- close_time: tiempo de cierre del intervalo
- quote_asset_volume: volumen en moneda cotizada

- number_of_trades: número de transacciones
- taker_buy_base_asset_volume: volumen comprador
- taker_buy_quote_asset_volume: volumen comprador en cotización

A partir del dataset, se definieron variables relevantes para describir el comportamiento del mercado:

Tabla 1. Variables de caracterización.

Variable	Dominio	Estadística conocida	Comentarios
symbol (categórica)	BTCUSDT ETHUSDT XRPUSDT	33.3% c/u (1,052,560 registros por par)	Distribución perfectamente uniforme entre los 3 pares seleccionados
open / high low / close (numérica)	BTC: [16,506 – 108,258] ETH: [1,191 – 4,104] XRP: [0.317 – 2.889]	Media BTC: 47,377 Media ETH: 2,419 Media XRP: 0.623	Rangos heterogéneos según capitalización. BTC como activo de referencia
volume (continua)	BTC: [0 – 5,877] ETH: [0 – 26,966] XRP: [0 – 4.3×10 ⁷]	StdDev alta en los 3 pares. Mediana cercana a 0	Alta varianza por picos de liquidez en eventos de mercado
number_of_trades (discreta)	BTC: [0 – 149,713] ETH: [0 – 63,751] XRP: [0 – 73,730]	Media BTC: 1,854 Media ETH: 913 Media XRP: 339	Refleja la liquidez relativa de cada par. BTC lidera por amplio margen
return_pct (continua derivada)	BTC: [-3.68%, 3.16%] ETH: [-8.40%, 4.88%] XRP: [-9.84%, 9.79%]	Media ≈ 0 en los 3 pares StdDev BTC: 0.067 StdDev XRP: 0.116	XRP con mayor amplitud de retornos — activo más volátil y especulativo
intrabar_volatility_pct (continua derivada)	[0%, 17.2%] (máx en XRP)	Media BTC: 0.065% Media ETH: 0.077% Media XRP: 0.114%	Volatilidad intrabar mayor en activos de menor capitalización
market_direction (categórica derivada)	bullish bearish neutral	bullish: 47.3% bearish: 45.5% neutral: 7.2%	Distribución ligeramente asimétrica hacia bullish en el periodo 2023-2024

market_session (categórica derivada)	Asia (00:00–07:59) Europe (08:00–15:59) America (16:00–23:59)	~33.3% c/u (ventanas de 8h equitativas)	Distribución uniforme por construcción — sesiones de igual duración
market_period (categórica derivada)	EARLY (<2020) BULL (2020-2021) MODERN (2022+)	Dataset activo 2023-2024 = periodo MODERN (100% del subconjunto)	Definido por rangos temporales históricos del ecosistema cripto

Derivado de las variables principales de caracterización se generaron variables adicionales para complementar el análisis:

- **Volatilidad intrabar:** $\text{volatility} = (\text{high} - \text{low}) / \text{open}$
- **Retorno porcentual:** $\text{return_pct} = (\text{close} - \text{open}) / \text{open} (100)$

Se realizó un análisis segmentado por símbolo utilizando estadísticas descriptivas:

- media
- desviación estándar
- valores mínimos y máximos
- percentiles

```
[37] ✓ 3 m # Estadísticas por símbolo

characterization_cols = [
    "open",
    "high",
    "low",
    "close",
    "volume",
    "quote_asset_volume",
    "number_of_trades",
    "return_pct",
    "intrabar_volatility_pct"
]

for symbol in ["BTCUSD", "ETHUSD", "XRPUSD"]:

    print("\n" + "=" * 80)
    print(f"ESTADÍSTICAS PARA {symbol}")
    print("=" * 80)

    df.filter(col("symbol") == symbol)
       .select(characterization_cols)
       .describe()
       .show(truncate=False)
```

Imagen 1. Celda de código para generación de estadísticas por símbolo

ESTADÍSTICAS PARA BTCUSDT									
summary	open	high	low	close	volume	quote_asset_volume	number_of_trades	return_pct	intraday_volatility_pct
count	1052560	1052560	1052560	1052560	1052560	1052560	1052560	1052560	1052560
mean	47376.759991289546	47393.02172609942	47360.275108590875	47376.83274387907	47.06282670792255	1681638.5322825809	1854.2881336930911	1.870145028549902E-4	0.00532655932219454
stddev	21659.552106870124	21669.034764146945	21649.938144630127	21659.57756532099	104.1195493879306	2969740.139981635	2681.7841715598074	0.06733333341365537	0.07662313257857664
min	16506.04	16508.73	16499.01	16505.87	0.0	0.0	0	-3.675565153488311	0.0
max	108258.38	108353.0	108168.0	108258.39	5877.77545	2.598501487256762E8	149713	3.155336964604663	5.925637690698017

ESTADÍSTICAS PARA ETHUSD									
summary	open	high	low	close	volume	quote_asset_volume	number_of_trades	return_pct	intraday_volatility_pct
count	1052560	1052560	1052560	1052560	1052560	1052560	1052560	1052560	1052560
mean	2419.4751646461746	2420.4588080869826	2418.471347258127	2419.4771858611375	270.2716707829467	668771.5483359871	912.5169885559018	1.279469141079577E-4	0.07690691917688232
stddev	738.675958043884	739.1769325743384	738.1602958042134	738.6755238377493	508.2854184962439	1283271.0309189425	1543.6486776652418	0.07830695555862024	0.08826679327193697
min	1191.54	1192.09	1190.57	1191.54	0.0	0.0	0	-8.403544730615817	0.0
max	4104.27	4107.8	4097.14	4104.27	26966.4364	9.7572886088708E7	63751	4.877137251237975	10.889474067069178

ESTADÍSTICAS PARA XRPUSD									
summary	open	high	low	close	volume	quote_asset_volume	number_of_trades	return_pct	intraday_volatility_pct
count	1052560	1052560	1052560	1052560	1052560	1052560	1052560	1052560	1052560
mean	0.623282173177791	0.6237104776259944	0.6228406465189719	0.6232980089496327	278954.88250224217	199985.05852871295	339.44572660940946	0.0030303573889637245	0.11439580414414173
stddev	0.3884588734818802	0.3890647556456411	0.38784085683709374	0.3884578686620571	534924.3611107166	566761.4108489879	961.7262374976108	0.11630867500974104	0.14429057073409735
min	0.3168	0.3188	0.3	0.3167	0.0	0.0	0	-9.838472834067547	0.0
max	2.8893	2.9892	2.8711	2.8893	4.3026148E7	6.8398157907947E7	73730	9.785251215559171	17.196778654518834

Imagen 1.1.Salida de estadísticas por símbolo

Este análisis permitió identificar diferencias estructurales entre BTCUSDT, ETHUSD y XRPUSD, observando variaciones significativas en volumen, volatilidad y actividad de trading.

Particionamiento

Con base en las variables de caracterización identificadas, se definieron tres dimensiones de particionamiento que permiten segmentar el dataset D en subconjuntos homogéneos:

- **A = Symbol:** representa el activo financiero (BTCUSDT, ETHUSD, XRPUSD).
- **B = Volatility Level:** representa el nivel de volatilidad del mercado (LOW, MEDIUM, HIGH).
- **C= Market Period:** representa el periodo temporal del mercado (EARLY, BULL, MODERN).

Cada una de estas variables presenta diferentes niveles de ocurrencia dentro del dataset, lo cual permite definir un espacio de combinaciones estratificadas.

Para fines del diseño del particionamiento, se asume la siguiente estructura de distribución:

Variable	Valor	Registros	P(valor)
symbol	BTCUSDT	1,052,560	0.333
symbol	ETHUSDT	1,052,560	0.333
symbol	XRPUSDT	1,052,560	0.333
volatility_level	LOW	~940,370 (estimado)	~0.894
volatility_level	MEDIUM	~108,775 (P3 BTC)	~0.103
volatility_level	HIGH	~3,415 (P1 BTC)	~0.003
market_period	MODERN	3,157,680	1.000
market_period	EARLY	0	0.000
market_period	BULL	0	0.000

A partir de las variables anteriores, se generan combinaciones cartesianas de particiones:

$A \in \{\text{BTC,ETH,XRP}\}$

$B \in \{\text{LOW,MEDIUM,HIGH}\}$

$C \in \{\text{EARLY,BULL,MODERN}\}$

Esto produce un total de: $3 \times 3 \times 3 = 27$ posibles particiones

Se definen algunas particiones representativas implementadas en PySpark:

ID	Symbol	Volatility	Period	Registros	P(combinación)
P1	BTCUSDT	HIGH	MODERN	3,415	$0.333 \times 0.003 \times 1.0 = 0.10\%$
P2	ETHUSDT	LOW	MODERN	794,683	$0.333 \times 0.894 \times 1.0 = 29.8\%$
P3	BTCUSDT	MEDIUM	MODERN	108,775	$0.333 \times 0.103 \times 1.0 = 3.43\%$
P4	XRPUSDT	HIGH	MODERN	18,980	$0.333 \times 0.003 \times 1.0 = 0.10\%$

Cada partición corresponde a un subconjunto del dataset original D, obtenido mediante reglas de filtrado sobre las variables de caracterización.

```
Partición 1

[44] from pyspark.sql.functions import col

p1 = df.filter(
    (col("symbol") == "BTCUSDT") &
    (col("volatility_level") == "HIGH") &
    (col("market_period") == "MODERN")
)

print("P1 count:", p1.count())
p1.show(5, truncate=False)

... P1 count: 3415
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
|open_time|open|high|low|close|volume|close_time|quote_asset_volume|number_of_trades|taker_buy_base_asset_volume|taker_buy_quote_asset_volume|ignore|
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
|[1673811800000]|16688.62|16794.26|16679.0|16749.07|2946.96988|[1673811859999]|4.93201511957976E7|144806|1456.32969|2.43777031488838E7|0|
|[1673219340000]|17003.88|17096.0|17001.07|17041.13|2003.80496|[1673219399999]|3.41669182127358E7|27746|1129.12074|1.92525273675736E7|0|
|[1673222200000]|17081.75|17176.99|17081.31|17116.89|1629.48448|[1673222799999]|2.79164658392133E7|24701|1012.59575|1.7344384741237E7|0|
|[1673460660000]|17476.35|17571.7|17475.07|17536.89|2290.72385|[1673460719999]|4.01336986385381E7|24548|1207.04213|2.11486268668588E7|0|
|[1673479620000]|17580.75|17702.78|17578.96|17672.0|1931.05517|[1673479679999]|3.48703229449154E7|27052|1123.50296|1.98204780046511E7|0|
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
only showing top 5 rows
```

Imagen 2. Partición 1.

```
Partición 2

[51] from pyspark.sql.functions import col

p2 = df.filter(
    (col("symbol") == "ETHUSDT") &
    (col("volatility_level") == "LOW") &
    (col("market_period") == "MODERN")
)

print("P2 count:", p2.count())
p2.show(5, truncate=False)

... P2 count: 794683
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
|open_time|open|high|low|close|volume|close_time|quote_asset_volume|number_of_trades|taker_buy_base_asset_volume|taker_buy_quote_asset_volume|ignore|
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
|[1733011200000]|3703.59|3704.63|3703.5|3704.05|197.7099|[1733011259999]|732291.556881|1700|94.3481|349443.40806|0|
|[1733011260000]|3704.06|3706.97|3703.84|3706.34|208.7054|[1733011319999]|773275.401307|2890|110.8381|410666.623148|0|
|[1733011440000]|3714.83|3714.83|3713.27|3713.32|277.0572|[1733011499999]|1028970.269614|1700|65.4497|243058.277521|0|
|[1733011500000]|3713.33|3713.33|3710.0|3710.02|240.3331|[1733011559999]|891936.388472|2898|62.9645|233652.603806|0|
|[1733011560000]|3710.01|3712.41|3710.01|3710.22|272.7962|[1733011619999]|1012461.741234|2454|159.296|591185.189282|0|
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
only showing top 5 rows
```

Imagen 3. Partición 2.

Partición 3

```

[49]
✓ 1m
from pyspark.sql.functions import col

p3 = df.filter(
    (col("symbol") == "BTCUSDT") &
    (col("volatility_level") == "MEDIUM") &
    (col("market_period") == "MODERN")
)

print("P3 count:", p3.count())
p3.show(5, truncate=False)

```

P3 count: 198775

open_time	open	high	low	close	volume	close_time	quote_asset_volume	number_of_trades	taker_buy_base_asset_volume	taker_buy_quote_asset_volume	ignore
1672542000000	16548.19	16548.19	16531.47	16533.94	344.42893	1672542059999	5696296.0186831	6966	133.83383	2213223.4798241	0
1672557360000	16526.09	16528.94	16510.0	16511.5	282.89554	1672557419999	4672593.3690108	4724	88.44782	1460928.5332817	0
1672588920000	16564.84	16584.66	16563.68	16574.35	448.30474	1672588979999	7429514.7094269	7990	265.37495	4397911.1902205	0
1672621560000	16579.54	16579.91	16560.0	16566.84	749.40681	1672621619999	1.24152381061808E7	14601	355.36484	5887436.835441	0
1672631580000	16619.19	16693.41	16618.29	16673.13	1452.91291	1672631639999	2.42035173705488E7	20112	901.16617	1.50117078762672E7	0

only showing top 5 rows

Imagen 4. Partición 3.

Partición 4

```

[59]
✓ 1m
from pyspark.sql.functions import col

p4 = df.filter(
    (col("symbol") == "XRPUSDT") &
    (col("volatility_level") == "HIGH") &
    (col("market_period") == "MODERN")
)

print("P4 count:", p4.count())
p4.show(5, truncate=False)

```

P4 count: 18900

open_time	open	high	low	close	volume	close_time	quote_asset_volume	number_of_trades	taker_buy_base_asset_volume	taker_buy_quote_asset_volume	ignore
1733011200000	1.9514	1.955	1.9409	1.9427	1985573.0	1733011259999	3877994.5198	6871	1229964.0	2481358.2114	0
1733011260000	1.9426	1.9433	1.9246	1.9278	1999504.0	1733011319999	3864387.5567	18902	834019.0	1611467.2345	0
1733011500000	1.9362	1.9487	1.9362	1.947	1085407.0	1733011559999	2109145.1266	5815	630423.0	1224661.0063	0
1733011560000	1.9471	1.9568	1.9421	1.9452	2209018.0	1733011619999	4312763.4514	8114	1377577.0	2689862.2539	0
1733011620000	1.9452	1.9544	1.9434	1.9509	887790.0	1733011679999	1730663.2752	5050	444017.0	865575.606	0

only showing top 5 rows

Imagen 5. Partición 4.

El particionamiento permite segmentar la población en grupos homogéneos que capturan diferentes comportamientos del mercado:

- BTCUSDT representa el activo dominante con alta liquidez.
- ETHUSDT representa un comportamiento intermedio del mercado.
- XRPUSDT representa un activo más volátil y especulativo.

Por otro lado:

- Los niveles de volatilidad permiten distinguir entre condiciones de estabilidad y riesgo.
- Los periodos de mercado permiten capturar cambios estructurales en el comportamiento histórico del ecosistema cripto.

Implementación de Notebook en PySpark:

 **Copy of Full Binance History.ipynb**

Técnica de muestreo a aplicar por partición

Para la construcción de la muestra M se propone el muestreo aleatorio estratificado, donde cada partición (estrato) definida en la sección B constituye una unidad de muestreo independiente. Dentro de cada estrato se aplica muestreo aleatorio simple (MAS), garantizando que todas las observaciones del subconjunto tengan igual probabilidad de selección.

Las tres dimensiones de particionamiento justifican la elección del muestreo estratificado:

- Evita sesgo de activo financiero: al muestrear proporcionalmente de cada par (BTC, ETH, XRP), se impide que el activo con mayor volumen de operación domine la muestra. Sin estratificación, BTC tendería a sobrerrepresentar por su mayor actividad.
- Evita sesgo de volatilidad: la variable `volatility_level` captura regímenes de mercado estructuralmente distintos (LOW $\approx 89\%$, MEDIUM $\approx 10\%$, HIGH $\approx 1\%$). Sin estratificación, los episodios de alta volatilidad (HIGH) quedarían subrepresentados por su baja frecuencia, aunque son los de mayor interés para modelos predictivos de riesgo.
- Evita sesgo temporal: aunque el dataset actual es 100% MODERN, el diseño de particionamiento por `market_period` permite extender el análisis a periodos EARLY y BULL en etapas posteriores, garantizando cobertura temporal completa sin reescribir el pipeline de muestreo.
- Representatividad garantizada: al aplicar la fracción de muestreo proporcional a $P(A_i, B_j, C_k)$ dentro de cada estrato, la muestra M refleja fielmente la distribución conjunta de la población P , preservando la estructura de volatilidad y comportamiento de cada activo.
- Compatibilidad con PySpark: el método `df.sampleBy()` permite muestreo estratificado distribuido, sin materializar datos en memoria.

Referencias:

- Ahmed, S. K. (2024). How to choose a sampling technique and determine sample size for research: a simplified guide for researchers. *Oral Oncology Reports*, 12, 100662.
- Kim, J. K., & Wang, Z. (2019). Sampling techniques for big data analysis. *International Statistical Review*, 87, S177-S191.